

گزارش پروژه درس بیوانفورماتیک

عنوان پروژه:

شناسایی ژنهای آنزیم زیالناز از متازنوم شکمبه
نشخوارکنندگان

سرگروه: امیرمحمد محمدحسینی (610701036)

اعضای گروه:

پدرام دلیری (610700005)

علی اسدی (610799022)

استاد درس:

دکتر کاوه کاووسی

نیمسال دوم سال تحصیلی 1402-1403

مقدمه:

آنزیم زایلاناز یکی از آنزیم های حیاتی و پر کاربرد در صنایع مختلف است. به ویژه در تخریب دیواره های سلولی گیاهان که طی آن هم سلولز تجزیه می شود. توانایی زایلاناز در هیدرولیز زایلان به زایلوز و سایر قندها، این آنزیم با سفید کردن و بهبود کیفیت کاغذ در صناعی مانند تولید کاغذ و خمیر کاغذ ارزش بسیاری دارد، همچنین در تولید سوخت های زیستی نقش مهمی در تبدیل Biomass به قند های قابل تخمیر دارد. علاوه بر این، زایلاناز در صنعت غذا برای بهبود کیفیت خمیر و نان و همچنین در خوراک دام برای افزایش جذب مواد مغذی استفاده می شود.

هدف این پروژه تحلیل و بررسی توالی های ژن زایلاناز در میکروارگانیسم های مختلف است تا درک بهتری از تفاوت های آنها و نواحی حفاظت شده (conserved region) به دست بیاوریم. در نتیجه می توان با درک اساس ژنتیکی زایلاناز و سویه های مختلف آن به دنبال یافتن آنزیم های بهتر، کارآمد تر و مقاوم تر در کاربرد های صنعتی است.

مرحله اول:

فایل اولیه ای که در اختیار ما قرار گرفته حاوی توالی های کانٹیک اسمبل شده ای از متاژنوم نشخوارکنندگان است. از آنجا که سیستم های توالی یابی تا طول های چند صد نوکلئوتیدی (400-500 bp) را خوانده برای رسیدن به توالی کامل ژنوم این توالی های چند صد نوکلئوتیدی (contig) از نواحی مشترک با یکدیگر assemble شده و توالی های بلندتری به وجود می آورند.

به منظور فایتر کردن تعدادی از توالی های دارای پتانسیل بالا برای کد کردن زیلاناز ها، تصمیم بر آن شد تا با استفاده از تکنیک Sequence Alignment با استفاده از ابزار Blast+ و HMMER، یک معیار برای جداسازی ایجاد کنیم. داده های زیلاناز موجود در پایگاه داده ncbi (Sayers *et al.*, 2022) دارای طول کمتر از 100 هزار جفت باز بعنوان دیتابیس رفرنس برای انجام Blast و ترین کردن HMMER مورد استفاده قرار گرفت. با در نظر گرفتن پارامترهای زیر

e-value = 1e-9 , similarity score = 80 , minimum alignment length = 100

توالی های دارای شباهت توسط نتایج Blast (Camacho *et al.*, 2009) فیلتر شدند.


همچنین با در نظر گرفتن e-value = 1e-9 , alignment coverage = 80% توالی های مشابه بوسیله HMMER (Finn, Clements and Eddy, 2011) فیلتر شدند.

اشتراک توالی های فیلتر شده بوسیله این 2 تکنیک در نظر گرفته شد و حدود 9000 توالی از دیتاست ابتدایی جدا شدند.

برای محدودتر کردن توالی های انتخاب شده به منظور کاهش computation units مورد نیاز و دقیق تر کردن پروسه فیلتراسیون، از تکنیک PSI Blast (Altschul *et al.*, 1997) استفاده شد تا یک ماتریس PSSM برای توالی های زیلاناز موجود در دیتابیس NCBI تهیه شود.

PSSM score threshold = 40 برای توالی های با طول بلندتر از 50000 و PSSM score threshold = 25 برای توالی های با طول کمتر از 50000 در نظر گرفته شد. تا توالی هایی با شباهت بیشتر از میان 9000 توالی انتخاب شده در مرحله قبل، فیلتر شده و مورد استفاده قرار گیرند.

2254 توالی در نهایت بوسیله تکنیک های نامبرده فیلتر شده تا مورد بررسی قرار بگیرند. (Scheme 1.1)



Scheme 1.1 Distribution of Blast+ ,HMMER and PSI Blast derived filtered data compared to crude dataset. a, Venn diagram of the whole dataset compared to the 4 sets of filtered data with respect to

the adjusted thresholds. **b**, distribution of 2 levels of data filtering compared to the whole dataset, utilizing 3-mer vectorization (Iuchi *et al.*, 2021) accompanied by Principal Component Analysis (Maćkiewicz and Ratajczak, 1993) method in order to attain a 2 dimensional representation.

2254 توالی فیلتر شده بوسیله تکنیک CD-HIT (Li and Godzik, 2006) به منظور شناسایی توالی های دارای ایزوفرم یا توالی های بسیار مشابه در کلاسترهای مبنی بر شباهت ساختاری (آستانه 0.97) طبقه بندی شدند. 2254 توالی جدا شده در 1865 کلاس، طبقه بندی شدند.

مرحله دوم

کلاسی از خانواده زایلانازها که در این پایپلاین قصد انتخاب (تفکیک) آن از سایر زایلانازها را داریم خانواده 10 گلیکوزید هیدرولازها (Glycoside Hydrolase Family 10) (Drula *et al.*, 2022) هستند، بنابراین داده های مثبت در گروه GH10 قرار داشته که حدود 5000 توالی در دسترس بودند و گروه هیدرولازهای GH8, GH9, GH11, GH12 به عنوان داده های منفی انتخاب شدند که در مجموع حدود 10000 توالی را شامل می شدند.

اینکه مدل بر روی چه نوع داده توالی train شود قابل بحث است. دیتایست مورد جستجو در این گزارش توالی DNA بوده، اما توالی های DNA طول بلندتری داشته و به عنوان مثال train کردن مدل های ترنسفورمر بر روی آنها می تواند چالش زا باشد. می توان از توالی های پروتئین ترجمه شده از روی DNA مذکور نیز بعنوان دیتاست train کردن مدل بهره برد. بدین منظور توالی های DNA می توانند با سه فریم مختلف (شروع از نوکلئوتید فرضی 1 الی 3) ترجمه شده تا نهایتاً از توالی های آمینواسیدی منتج از آنها برای train کردن مدل ها استفاده کرد.

به منظور انتخاب و ترین مدل بر روی توالی های پروتئینی بدست آمده از هر ژن، 2 رویکرد را بررسی کردیم:

- بررسی sequence-based توالی ها با طراحی یک Encoder-Only Transformer Architecture (Vaswani *et al.*, 2017) به منظور کسبای کردن و اسکورینگ توالی های پروتئینی.

- بررسی توالی ها با استفاده از feature های مناسب و سپس بررسی آنها بوسیله ی مدل های یادگیری ماشین.


معماری ترنسفورمر به منظور دقت بالاتر و سرعت ترین شدن نسبتاً بالاتر نسبت به ساختار های دیگر چون Recurrent Neural Networks (RNN) انتخاب شد.

داده های توالی های پروتئینی بر اساس طول فیلتر شده تا ماکسیمم طول توالی که از مدل عبور میکنند 512 توکن باشد. بدلیل unbalanced بودن دیتاست مورد نظر، تکنیک oversampling بر روی توالی های GH10 انجام شد تا تعداد دیتا 2 کلاس برابر شوند، برای این منظور، یک Markov Chain (Ching *et al.*, 2013) ساده طراحی شد تا با میزان تنظیم شده، با ایجاد نویز توالی های مشابه و غیرواقعی ایجاد کند. (Scheme 2.1). پس از Tokenization، دیتا حاصل برای ترین کردن مدل استفاده شد. پس از بررسی مدل برای بدست آوردن عملکرد بهینه، هایپرپارامتر های بهینه به منظور عملکرد مدل تعیین شدند (table 2.1)


به منظور بررسی عملکرد مدل، نمودارهای مربوط به 10-fold cross validation and Receiver Operating Characteristic Curve (ROC) (Metz, 1978) تهیه و تحلیل شدند. (Scheme 2.2a,b)

Table 2.1 Obtained Optimum training and hyperparameters of model.

Optimum hyperparameters	Batch size	Learning rate	Number of embedding layers	Number of attention layers	Number of attention heads	Number of epochs	Optimizer
	64	0.0008	192	6	6	11	AdamW (Zhuang <i>et al.</i> , 2022)



Scheme 2.1 Distribution of the GH10 (Positive class) sequences before and after oversampling using a Markov Chain.




Scheme 2.2 Model performance assessing

diagrams a, Receiver Operating Characteristic

Curve (ROC), exhibits a promising performance and the obtained optimum threshold of models scores.

b, 10-fold cross validation result after 30 epochs. (early stopping at epoch 11)

رویکرد دیگر، استفاده از روش های feature extraction به منظور بررسی توالی ها است. به منظور انجام این تکنیک از روش (Li, Li and Lin, 2016) (Mu *et al.*, 2021) FEGS (Feature Extraction based on Graphical and Statistical) استفاده شد. این روش با استفاده از خواص فیزیکی و شیمیایی متفاوت مربوط به هر آمینواسید، 20 آمینواسید را به ترتیب سورت کرده و بر مبنای هر نوع ترتیب دهی به آمینواسید ها یک ماتریکس متشکل از فاصله ی فضایی هر آمینواسید از آمینو اسید های بعد از خود در مختصات فرضی تولید می کند. 158 خاصیت شیمیایی و فیزیکی (Mu *et al.*, 2021) متفاوت در نظر گرفته شده که منجر به تولید 158 ماتریکس متفاوت به ازای هر توالی پلی پپتیدی می شوند. به منظور یکسان کردن تعداد feature ها برای تمامی توالی ها مستقل از طول آنها، ویژه مقدار هر ماتریکس محاسبه شده و به شکل یک feature مورد استفاده قرار می گیرد. علاوه بر این 158 feature بدست آمده، 20 عدد مربوط به فرکانس تکرار هر آمینواسید و 400 عدد مربوط به فرکانس اعداد هر جفت آمینواسید بدست آمده و به همراه 158 فیچر مربوطه، نمایش مربوط به هر توالی را در غالب یک رشته 578 عضوی تشکیل می دهند. (Scheme 2.3)





Scheme 2.3 Mechanism of FEGS (Feature Extraction based on Graphical and Statistical) method (figure is provided from the original paper¹) (Mu *et al.*, 2021)

پس از تهیه فیچر مربوط به توالی های موجود در دیتاست، مدل های متفاوت یادگیری ماشین روی داده ها تست شد تا نتایج با یکدیگر مقایسه و بررسی شوند. نتایج عملکرد مدل ها در پیشبینی test data در غالب 4 پارامتر حاصل از confusion matrix بررسی شد. (Table 2.2) Random Forest Classifier دارای عملکرد بهتری نسبت به مدل های دیگر بود. نکته دارای اهمیت اینکه استفاده از Graphical Features 158 ابتدا تفاوت خاصی نسبت به استفاده از تمامی 578 features ایجاد نمی کند. پس به منظور کاهش کامپیوتیشن های مدل و ساده تر کردن مدل، تصمیم به استفاده از تنها 158 فیچر اول گرفتیم.

به منظور مقایسه ی بهتر و دقیق تر، نمودار ROC و AUC (Area Under Curve) مربوط به هر مدل در طی 10-fold cross validation تهیه و گزارش شد. (Scheme 2.4 a,b) (Refaeilzadeh, Tang and Liu, 2009)


Table 1) Model Comparison	Accuracy Score	Sensitivity (True Positive Rate)	Specificity	Positive Predictive Value (PPV)
Random Forest with 578 features	0.99	0.99	1.00	1.00
Random Forest with 158 features	0.99	0.97	0.99	0.98
SVC(kernel: rbf)	0.98	0.96	0.99	0.97
SVC(kernel:linear)	0.81	0.39	1.00	0.98
SVC(kernel:polynomial)	0.97	0.96	0.98	0.96
Naive Bayse	0.63	0.85	0.53	0.45
XGBoost	0.99	0.98	0.99	0.98
Neural Network	0.79	0.68	0.84	0.66

Table 2.2 Models Comparison after being trained on feature extracted training dataset.




Scheme 2.4 ROC curve and violin plots for Area Under Curves(AUC) values during 10 fold cross validation for model comparison.

با توجه به عملکرد بهتر و قابل قبول مدل (Random Forest Classifier ($n_ensembles = 100$, criterion = "entropy") تصمیم گرفتیم تا این مدل را بدلیل سادگی بیشتر نسبت به مدل ترنسفورمر و همچنین عملکرد بهتر برگزینیم. برای بررسی دقیق تر، تاثیر انتخاب تعداد feature ها بر عملکرد مدل را مورد بررسی قرار داده تا حد امکان بتوانیم ساده ترین مدل را با حفظ عملکرد مناسب انتخاب و بدست آوریم. پارامتر AUC را بعنوان معیار عملکرد مدل قرار داده و طی 10-fold cross validation مقادیر آنرا برای مدل ترین شده با تعداد متفاوت feature گزارش و مقایسه کردیم تا بتوان تاثیر تعداد فیچر های train dataset را بر عملکرد مدل بررسی کرد. (Scheme 2.5) نمودار Specificity/Threshold نیز به منظور تعیین حد اسکور بهینه برای مدل به منظور کسیفیکیشن بررسی شد. (Scheme 2.6)



Scheme 2.5 Alteration of the number of features allocated to represent the data on the AUC scores of the model




Scheme 2.6 Specificity/threshold diagram in order to attain the optimum classification score threshold



از آنجا که فیچرهای مورد استفاده در ترین مدل ، از خواص فیزیکی و شیمیایی مربوط به هر آمینواسید بدست آمده اند. میتوان با بررسی میزان تاثیر گذاری هر فیچر در اسکور دهی مدل، نسبت به اهمیت و تاثیرگذاری خاصیت شیمیایی مربوطه به هر فیچر در خواص بروز پیدا کرده از خانواده Glycoside Hydrolase Family 10(GH10) اظهار نظر های جالبی کرد.

با انجام تست SHAP test (SHapley Additive exPlanations) (Lundberg and Lee, 2017)، میزان contribution هر فیچر در اسکوردهی مدل را میتوان بررسی کرد. داده های حاصل از این آنالیز نشان دهنده ی آن است که 4 فیچر f89 , f99 , f111,f113 بیشترین تاثیر را در اسکور دهی مدل داشته و اسکور تولید شده از مدل بیشتر تحت تاثیر این 4 فیچر است. این 4 فیچر به ترتیب تولید شده از سورت شدن آمینواسید ها بر طبق 4 خاصیت فیزیکی Information measures for middle helix , Relative population of conformational state C , p-value of Thermophilic proteins based on the distribution of B values, Average interaction per side chain atom (Scheme 2.7) میتوان ادعا کرد که مدل ماشین لرنینگ مورد

استفاده توسط ما، این 4 ویژگی را مهم تر و بر اهمیت تر برای تفاوت قائل شدن بین اعضا خانواده GH10 و سایر خانواده ها پیدا کرده است. راجع به نحوه ی ارتباط این ویژگی ها اما نمی توان سخنی قطعی مطرح کرد به دلیل آنکه میزان پراکندگی داده در دو سمت مثبت و منفی تست، تقریباً یکسان است، احتمال می رود که تاثیر این پارامتر ها به صورت ترکیبی بوده و به سادگی رفتار آنها ثابلی بررسی نباشد.




Scheme 2.7 (Shapley Additive exPlanations)SHAP test result of trained model attesting the contribution of different features in model's scoring.



مرحله سوم:

با استفاده از مدل برگزیده، اسکور تمام توالی های پروتئینی مربوط به اعضا هر کلس را بدست آورده و از هر کلس، توالی با اسکور بالاتر را انتخاب کردیم تا در ادامه از آن ها برای بررسی های ساختاری استفاده کنیم. یک زایلاناز از خانواده GH10 (<https://doi.org/10.2210/pdb7D88/pdb>) به عنوان رفرنس انتخاب شد تا شباهت های ساختاری توالی های برگزیده خود را نسبت آن مقایسه شوند. از میان توالی های موجود، 3 توالی دارای بیشترین شباهت ساختاری با توالی رفرنس انتخاب و به عنوان کاندیدای محتمل تر برای زایلاناز خانواده GH10 گزارش شدند (Table 3.1)

a



b



Scheme 3.1 ESMfold derived predicted pdb file and 3D representation of **a**, XylNA 7D88 and **b**, k141_5880259

	ID	Predicted Score	TM-score (normalized Chain):	TM-score (normalized reference chain)	RMSD
Sequence 1	k141_1319095	0.78	0.80750	0.65432	1.6
Sequence2	k141_5880259	0.64	0.74323	0.43092	1.72
Sequence 3	k141_1706080	0.49	0.76794	0.30720	1.79

Table 3.1 Structural Similarity Scores of top 3 most similar sequences from our dataset to the reference sequence (XylNA 7D88)

با توجه به نتایج بدست آمده در جدول بالا می‌توان بیان کرد که این سه توالی می‌توانند به عنوان توالی‌های کاندیدای زیالانازی شناخته شوند که از خانواده GH10 بوده چرا که شباهت ساختاری قابل قبولی با زیالاناز انتخاب شده به عنوان رفرنس مقایسه دارند.

از آنجایی که مدل انتخاب شده پس از ترین شدن دقت خوبی در استخراج و شناسایی ویژگی‌های فیزیکی و شیمیایی توالی‌های پروتئین نشان داده بود، این شباهت سه توالی از نظر ساختاری به توالی رفرنس می‌تواند بیانگر احتمال مناسب بودن این سه پروتئین جهت کاربردهای صنعتی بوده و میتوان در مراحل بعد با استفاده از روش های *in silico* مانند آلفافولد به طور دقیق‌تری ساختار آن را با آنزیمهای فعلی موجود در صنعت مقایسه کرد و امکان سنجی کاربری برای آنها متصور شد.

Supporting Materials and data:

اطلاعات مربوط به داده های مورد استفاده، داده های فیلتر شده، اطلاعات مربوط به ساختار های 3 بعدی بدست آمده برای انجام مقایسه و همچنین اطلاعات و فایل های مربوط به تمام مدل ها و تکنیک های ترین شده و استفاده شده در طی پروژه در صفحه گیت هاب مربوط به پروژه موجود و قابل دسترس است.

GitHub link: <https://github.com/AMIRMOHAMMAD-OSS/Bioinformatics>

References

- [1]Altschul, S.F. *et al.* (1997) 'Gapped BLAST and PSI-BLAST: a new generation of protein database search programs.', *Nucleic acids research*, 25(17), pp. 3389–3402. Available at: <https://doi.org/10.1093/nar/25.17.3389>.
- [2]Camacho, C. *et al.* (2009) 'BLAST+: architecture and applications.', *BMC bioinformatics*, 10, p. 421. Available at: <https://doi.org/10.1186/1471-2105-10-421>.
- [3]Ching, W.-K. *et al.* (2013) 'Markov Chains', 189. Available at: <https://doi.org/10.1007/978-1-4614-6312-2>.
- [4]Drula, E. *et al.* (2022) 'The carbohydrate-active enzyme database: functions and literature.', *Nucleic acids research*, 50(D1), pp. D571–D577. Available at: <https://doi.org/10.1093/nar/gkab1045>.
- [5]Finn, R.D., Clements, J. and Eddy, S.R. (2011) 'HMMER web server: interactive sequence similarity searching.', *Nucleic acids research*, 39(Web Server issue), pp. W29-37. Available at: <https://doi.org/10.1093/nar/gkr367>.
- [6]Iuchi, H. *et al.* (2021) 'Representation learning applications in biological sequence analysis', *Computational and Structural Biotechnology Journal*, 19, pp. 3198–3208. Available at: <https://doi.org/10.1016/j.CSBJ.2021.05.039>.
- [7]Li, C., Li, X. and Lin, Y.X. (2016) 'Numerical Characterization of Protein Sequences Based on the Generalized Chou's Pseudo Amino Acid Composition', *Applied Sciences* 2016, Vol. 6, Page 406, 6(12), p. 406. Available at: <https://doi.org/10.3390/APP6120406>.
- [8]Li, W. and Godzik, A. (2006) 'Cd-hit: a fast program for clustering and comparing large sets of protein or nucleotide sequences', *Bioinformatics*, 22(13), pp. 1658–1659. Available at: <https://doi.org/10.1093/BIOINFORMATICS/BTL158>.
- [9]Lundberg, S.M. and Lee, S.I. (2017) 'A Unified Approach to Interpreting Model Predictions', *Advances in Neural Information Processing Systems*, 2017-December, pp. 4766–4775. Available at: <https://arxiv.org/abs/1705.07874v2> (Accessed: 17 August 2024).
- [10]Maćkiewicz, A. and Ratajczak, W. (1993) 'Principal components analysis (PCA)', *Computers & Geosciences*, 19(3), pp. 303–342. Available at: [https://doi.org/10.1016/0098-3004\(93\)90090-R](https://doi.org/10.1016/0098-3004(93)90090-R).
- [11]Metz, C.E. (1978) 'Basic principles of ROC analysis', *Seminars in Nuclear Medicine*, 8(4), pp. 283–298. Available at: [https://doi.org/10.1016/S0001-2998\(78\)80014-2](https://doi.org/10.1016/S0001-2998(78)80014-2).
- [12]Mu, Z. *et al.* (2021) 'FEGS: a novel feature extraction model for protein sequences and its applications', *BMC Bioinformatics*, 22(1), pp. 1–15. Available at: <https://doi.org/10.1186/S12859-021-04223-3/TABLES/1>.

[13]Refaeilzadeh, P., Tang, L. and Liu, H. (2009) 'Cross-Validation', *Encyclopedia of Database Systems*, pp. 532–538. Available at: https://doi.org/10.1007/978-0-387-39940-9_565.

[14]Sayers, E.W. *et al.* (2022) 'Database resources of the national center for biotechnology information', *Nucleic acids research*, 50(D1), pp. D20–D26. Available at: <https://doi.org/10.1093/NAR/GKAB1112>.

[15]Vaswani, A. *et al.* (2017) 'Attention Is All You Need', *Advances in Neural Information Processing* [16]*Systems*, 2017-December, pp. 5999–6009. Available at: <https://arxiv.org/abs/1706.03762v7> (Accessed: 17 August 2024).

[17]Zhuang, Z. *et al.* (2022) 'Understanding AdamW through Proximal Methods and Scale-Freeness'. Available at: <https://arxiv.org/abs/2202.00089v1> (Accessed: 17 August 2024).